

PROJEKT DYPLOMOWY · ANALIZA DANYCH

HYROX: Analiza wyników par kobiet (grupa 35–39) na zawodach w Warszawie 2026



Autor: Aleksandra Dudek · Czerwiec 2026 · Dane: results.hyrox.com

HYROX Doubles · Kobiety 35–39 · Warszawa 2026 · 209 par · n8n → Supabase → Marimo



CZĘŚĆ 1 / 4

Hipoteza

Co sprawdzam i jakie pytanie zadaję danym.

W tej części: pytanie badawcze · hipoteza · definicje (bieg, stacje).

HIPOTEZA · CO ZAKŁADAM

H1: Zakładam, że czas biegu silniej idzie w parze z wynikiem niż czas stacji. To właśnie sprawdzimy na danych.

Bieg vs Stacje — co ma większy wpływ na wynik?

8×

BIEG

8 odcinków po ~1 km między stacjami.
łącznie **≈58%** czasu wyścigu.

VS

8×

STACJE

8 ćwiczeń funkcjonalnych (SkiErg, sanie x2rodzaje, burpee, wiosłowanie, spacer farmera, wypady z workiem, rzuty piłką lekarską).
łącznie **≈34%** czasu wyścigu.

Split — pojedynczy mierzony odcinek
(np. „Running 3” albo „1000m Row”).

Stacja — odcinek z ćwiczeniem siłowym
wykonywanym między biegami.

CZĘŚĆ 2 / 4

Dane i ich **pozyskanie**

Skąd pochodzą dane, jak je pobrałam i przygotowałam.

W tej części: źródło i zakres · automatyzacja n8n · Marimo.

Pobieranie danych **zautomatyzowane** w n8n

Źródło: results.hyrox.com

Filtr: Season 8 · 2026 Warsaw · HYROX Doubles · kobiety · grupa 35–39




Dlaczego automatyzacja? Ręczne przepisanie 209 par × 19 splitów to ~4000 wartości. Workflow robi to sam, a losowe opóźnienie między zapytaniami chroni przed zablokowaniem przez serwer.

Pięć tabel , zawody 2026 Warszawa

Tabela	Zawartość	Wiersze
results	wynik pary (Y)	209
workout_splits	splity biegu i stacji (X)	≈3 971
race_replay_splits	punkty z race replay	≈6 270
athletes	unikalne zawodniczki	417*
result_members	łączenie wynik↔osoba (M:N)	418

Uwaga: to prawdziwe dane, ale tylko jeden event — wnioski dotyczą tej próby, nie całego HYROX.
* 417 = unikalne zawodniczki: jedna osoba wystąpiła dwa razy (ta sama zawodniczka w dwóch parach albo identyczne imię+nazwisko+kraj), więc baza scalała ją w jeden wiersz

Ścieżka



Z surowego HTML do liczb gotowych do testu

KLUCZOWE KROKI

1

Czas → sekundy

„00:04:16” → 256 s, dla każdego splitu. tekst „00:04:16” zamieniany jest na liczbę 256 sekund, dla każdego splitu. Bez tego nie da się liczyć średnich ani korelacji.

2

Układ tabeli → Pivot long → wide

19 wierszy/parę → 1 wiersz × 19 kolumn. Zmiana układu tabeli: zamiast 19 wierszy na jedną parę (po jednym na każdy split) → 1 wiersz z 19 kolumnami. Dzięki temu jedna para = jeden rekord.

3

Sumy bloków

Sumujemy 8 czasów biegu w jeden łączny czas biegu (i tak samo dla stacji).

4

Filtr płci i grupy

Z całej bazy danych wybieramy tylko kobiety z grupy wiekowej 35–39.

konwersja czasu na sekundy

```
def to_sec(t):  
    h, m, s = t.split(":")  
    return int(h)*3600 + int(m)*60 + int(s)
```

PRZED

"Running 1"
→ "00:03:07"
(tekst, format
HH:MM:SS)



PO

run_1_sec
→ 187
(liczba, gotowa
do korelacji)

Outliery: sprawdzono rozkłady (histogram, boxplot) — brak błędnych rekordów do usunięcia; analiza na komplecie 209 par.

Kontrola danych przed analizą

0

braków w czasie
końcowym

0 / 209

0

zduplikowanych
wyników

0 / 209

0

dyskwalifikacji
i bonusów

0 / 209

0

odstających do
usunięcia (IQR)

kompletna próba

36

pary z karą
(17,2%)

36 / 209

WNIOSEK Z KONTROLI JAKOŚCI

Dane są **kompletne i bez duplikatów** — analizę prowadzimy na pełnej próbie 209 par, bez odrzucania wierszy.

Wartości skrajne to realne, wolne pary — nie pomyłki w danych.

KARY — OSTROŻNIE Z INTERPRETACJĄ

17,2% par ma zapisaną karę. Mediana ich czasu jest $\approx$ 6,5 min wolniejsza (92,0 vs 85,5 min).

Ale kara to pole tekstowe — nie wiadomo, czy jej sekundy są już doliczone do czasu. To obserwacja, **nie dowód przyczyny**; dlatego kary są poza główną hipotezą.

CZĘŚĆ 3 / 4

Analiza

Wykresy i ich interpretacja — co właściwie widać w danych.

W tej części: co było analizowane · wykresy zależności · wyjaśnienia.

Z czego składa się czas wyścigu?



Średni rozkład czasu jednej pary (czas końcowy ≈ 58 min). Skala odpowiada udziałowi procentowemu.

≈58%

udział biegu w czasie
największy komponent

≈34%


udział stacji w czasie
drugi co do wielkości

16

mierzonych odcinków
8 biegów + 8 stacji

Interpretacja: bieg jest największą częścią wyścigu — to daje mu naturalną przewagę, którą trzeba uwzględnić w interpretacji

Rozkład czasów końcowych — Doubles W 35–39



JAK CZYTAĆ TEN ROZKŁAD

75–95 min

zakres dominujący — tu mieści się większość par

1:26:44 mediana

1:27:22 średnia

Rozkład jest **prawoskośny** (skośność $\approx 0,60$): średnia leży na prawo od mediany, bo kilka bardzo wolnych par rozciąga skalę.

Do opisu „typowej” pary lepsza jest mediana.

Porównanie **blok biegu vs blok stacji**

- Dla każdej z 209 par sumujemy 8 czasów biegu i 8 czasów stacji.
- Mierzymy korelację każdej sumy z wynikiem (czas końcowy i miejsce).
- Korelacja = na ile dwie rzeczy idą w parze; im bliżej 1, tym mocniej.
- Różnicę między korelacjami sprawdzamy testem istotności (Steiger*).

Porównujemy całe bloki, nie pojedyncze odcinki — pojedynczy start biegu bywa słabszy niż wioślarz. Przewaga biegu bierze się z kumulacji ośmiu odcinków.

**To narzędzie statystyczne, które odpowiada na jedno pytanie: „Czy bieg naprawdę koreluje mocniej niż stacje, czy ta różnica mieści się w granicach przypadku?” Test bierze pod uwagę, że obie korelacje policzone są na tych samych parach (bieg i stacje nie są niezależne — to ci sami ludzie), i sprawdza, czy różnica jest na tyle duża, żeby uznać ją za realną.*

Jak czytać korelację (r)

Co to jest „r”?

r to **współczynnik korelacji** — liczba od **-1 do +1**, mówiąca, jak mocno dwie wartości idą w parze.

Im bliżej 1, tym ciaśniej punkty układają się wzdłuż linii — tym silniejszy związek.

Skala siły związku

	0,0–0,3	słaby
	0,3–0,6	umiarkowany
	0,6–0,8	silny
	0,8–1,0	bardzo silny


Nasze wyniki: bieg 0,96 i stacje 0,84 → oba „bardzo silne”.



Korelacja to nie to samo co przyczyna.

Wysokie r znaczy, że szybszy bieg **idzie w parze** z lepszym wynikiem — nie że bieg „powoduje” wynik. Dodatkowo bieg to ~58% wyścigu, więc część związku wynika z tego, że jest dużą częścią mierzonego czasu. Dlatego wniosek opieramy też na teście istotności (Steigera).

Punkty biegu układają się **ciaśniej** wzdłuż linii



Każdy punkt = jedna para.

- Niebieskie (bieg) leżą blisko linii → mocny związek.
- Szare (stacje) bardziej rozsypane → słabszy związek.

JAK CZYTAĆ TEN WYKRES

- Poziomo: czas danego bloku (min). Pionowo: czas końcowy pary (min).
- Linia = trend. Im ciaśniej punkty leżą przy swojej linii, tym silniejszy związek z wynikiem.
- Bieg jest w prawej części, bo trwa dłużej niż stacje — to naturalne, liczy się nachylenie i rozrzut.

Siła korelacji z wynikiem (r Pearsona)

Bieg (suma 8×)

$r = 0,96$

Stacje (suma 8×)

$r = 0,84$

Im bliżej 1,0, tym silniejsza zależność. Bieg ma niemal idealną korelację z wynikiem (0,96) — wyraźnie silniejszą niż stacje (0,84).

To znaczy: szybsze pary różnią się od wolniejszych przede wszystkim tempem biegu.

Uwaga metodologiczna: obie liczby pochodzą z notatnika Marimo. Korelacja to nie przyczyna — bieg to też ~58% czasu wyścigu, dlatego przewagę biegu potwierdzamy dodatkowo testem Steigera ($p < 0,001$).

Ile wyniku tłumaczy każdy komponent? (R^2)

93%

zmienności wyniku wyjaśnia BIEG

$R^2 = 0,93$


71%

zmienności wyniku wyjaśniają STACJE

$R^2 = 0,71$

Test Steigera (Williamsa): $t(206) \approx 11,3$, $p < 0,001$ — przewaga biegu nad stacjami jest istotna statystycznie i nie wynika z przypadku.

Najwolniejsze pary tracą **głównie w biegu**



- Od Q1 (najszybsze) do Q4 bieg rośnie o ~18 min.
- Stacje rosną tylko o ~8 min.
- O przepaść między grupami decyduje przede wszystkim bieg.

CZĘŚĆ 4 / 4

Wnioski i rekomendacje

Co z tego wynika i co z tym zrobić.

W tej części: ograniczenia · kluczowe wnioski · rekomendacje · odpowiedź.

KLUCZOWE WNIOSKI

Odpowiedź: **szybki bieg idzie w parze z wynikiem mocniej niż stacje**

0,96

korelacja biegu z wynikiem
r Pearsona

0,84

korelacja stacji z wynikiem
r Pearsona

93%

różnic w wyniku wyjaśnia bieg
 R^2 biegu

CO Z TEGO WYNIKA



Bieg jest najsilniejszym predyktorem wyniku

i to potwierdza się zarówno dla czasu końcowego, jak i dla miejsca w grupie ($\rho=0,96$ vs $0,81$).



Różnica jest istotna statystycznie

test Williamsa/Steigera: $t(206)\approx 11,3$, $p<0,001$ — przewaga biegu nie jest przypadkowa.



Bieg najmocniej różnicuje pary

między Q1 a Q4 bieg rośnie o ≈ 18 min, a stacje tylko o ≈ 8 min.



Trening biegowy daje największy zwrot

dla tej grupy to bieg jest dźwignią wyniku; stacje raczej „nie tracić” niż „nadrabiać”.

W PRAKTYCE?

**Wśród 10 najszybszych par
8 z nich biega najszybciej,
ale tylko 6 ma najszybsze stacje.**

O czołówce w tej grupie decyduje przede wszystkim to, jak para biega.

Dla trenerów: **przesuń trening na bieg**

- Jeśli para chce zejść poniżej mediany grupy (1:26:44) lub wejść do czołowych 25%, to priorytetem treningu zostaje bieg.
- Dlaczego bieg: między najlepszymi (Q1) a naj słabszymi (Q4) parami bieg różni się o $\approx 17,6$ min, a stacje tylko o ≈ 8 min — to tam jest największa dźwignia.
- Akcja: ok. 60–70% objętości treningowej na bieg, resztę na utrzymanie stacji; cel — łączny czas 8 biegów zbliżony do poziomemu Q1.
- Pomiar: kontrola łącznego czasu biegu co 4 tygodnie; jeśli po 8 tyg. brak poprawy — korekta planu.

Zastrzeżenie: to korelacja, nie dowód przyczyny — bieg jest też większą częścią wyścigu ($\approx 58\%$ czasu). Progi (mediana 1:26:44, Q1) pochodzą z tej próby 209 par, nie z całego HYROX.

Ograniczenia i ryzyka interpretacji



Jedna próba

Jeden event (Warsaw 2026), jedna dywizja, jedna grupa wiekowa. Wniosek dotyczy tej próby — nie uogólniamy na cały HYROX.



Korelacja ≠ przyczynowość

Mierzymy współwystępowanie, nie przyczynę. Bieg to też ≈58% czasu wyścigu, co naturalnie wzmacnia jego związek z wynikiem.



Niepewność kar

Kara jest polem tekstowym; z danych nie wynika jednoznacznie, czy sekundy są doliczone do czasu. Dlatego hipotezę o karach (H3) świadomie odrzucono.



Agregacja par

Analizujemy wynik pary, nie pojedynczych zawodniczek (relacja M:N). Indywidualny wkład każdej osoby jest poza zakresem tej analizy.