

HYROX — Analiza danych: co silniej idzie w parze z wynikiem?

Dataset: 2026 Warsaw / HYROX DOUBLES (Overall) — kobiety, grupa wiekowa 35–39 (209 par) Dane pobrane ze strony results.hydrox.com przez workflow n8n, zapisane do Supabase (Postgres) i wczytane do Marimo.

Płeć jest zapisana jawnie w kolumnie `results.sex ('W')` i filtrujemy po niej oraz po `age_group` (35–39) bezpośrednio w zapytaniu (sekcja 2) — nie polegamy na założeniu, że w bazie jest tylko jeden event. Relacja wynik↔zawodniczka jest typu **M:N** (`result_members`); w Doubles każda para to **2 wiersze**, dlatego do modelu $Y \sim X$ bierzemy wynik **pary** z `results`, a `athletes/result_members` służą tylko do flagi narodowości (H5).

? Pytanie badawcze

Co silniej idzie w parze z dobrym wynikiem pary w HYROX Doubles (kobiety, 35–39, Warszawa 2026): szybki bieg czy szybkie stacje funkcjonalne?

Cała praca jest podporządkowana temu jednemu pytaniu i przebiega w **trzech następujących po sobie etapach**:

- **Etap 1 — Eksploracyjna Analiza Danych (EDA):** wczytanie, czyszczenie, eksploracja i wizualizacja danych, a na końcu propozycja hipotez i wybór jednej do dalszej analizy.
- **Etap 2 — Analiza i weryfikacja hipotezy:** testy statystyczne (korelacja Pearsona i Spearmana, regresja, struktura czasu wg miejsca) sprawdzające, czy postawioną hipotezę da się potwierdzić, czy odrzucić.
- **Etap 3 — Wyniki, wnioski i rekomendacja:** synteza rezultatów, interpretacja w kontekście pytania badawczego, końcowa rekomendacja treningowa oraz przedstawienie wniosków w formie storytellingu, wraz z zastrzeżeniami metodologicznymi.

Wątki niezwiązane z tym pytaniem (narodowość par, Roxzone, kary) świadomie zostawiamy poza zakresem, aby zachować maksymalną spójność narracyjną.

Cel Etapu 1 (poniżej): wczytanie, czyszczenie, eksploracja i wizualizacja danych, a na końcu propozycja hipotez i wybór jednej do dalszej analizy.

ETAP 1: Eksploracyjna Analiza Danych (EDA)

Cel: poznać dane, oczyścić je, opisać i zwizualizować, a następnie zaproponować hipotezy i wybrać jedną do weryfikacji w Etapie 2.

1. Połączenie z bazą danych

```
podaj hasło Dudusrobiprojekt7;
```

2. Wczytanie tabel

Pięć tabel z bazy. Jeśli połączenie z bazą nie działa, zakomentuj `pd.read_sql` i odkomentuj `pd.read_csv` (pliki lokalne).

Rozmiary tabel:

Tabela	Wiersze	Kolumny
results	209	14
athletes	417	3
result_members	418	3
workout_splits	3971	5
race_replay_splits	6270	6

made with marimo

Kontrola filtra – w `results` po filtrze: `płeć = [ 'W' ]`, grupy wiekowe = `[ '35-39' ]`. Powinno być wyłącznie `[ 'W' ]` i jedna grupa 35-39. Jeśli `results` ma **0** wierszy, kolumna `sex` w bazie jest pusta (NULL) – uruchom `UPDATE`-y z `migration_add_sex.sql` albo przepuść workflow ponownie.

Mamy **209 par** (drużyn doubles). Każda para ma 2 zawodniczki, 19 splitów w `workout_splits` i komplet wejść/wyjść ze stref w `race_replay_splits`.

3. Przegląd surowych danych

Zanim cokolwiek policzymy, oglądamy **surowe dane „as is”** – metodą `.head()`, która pokazuje kilka pierwszych wierszy tabeli. Cel tego kroku to nie analiza, tylko **rozpoznanie**: jakie są kolumny, w jakim formacie zapisane są wartości i co trzeba będzie oczyścić przed liczeniem.

Tabela `results` (jeden wiersz = jedna para): na co zwracamy uwagę – czas końcowy (`overall_time`) jest zapisany jako **tekst** w formacie `HH:MM:SS`, a nie jako liczba; kara (penalty) to **opis słowny**, nie liczba sekund. To znaczy, że obu kolumn nie da się jeszcze użyć do obliczeń – trzeba je przekonwertować (robimy to w sekcji 4).

🔍 Search...

result_id	event_id	idp	bib_number	age_group	rank_overall	rank_age_group	overall_time	bonus	
int64	str	str	str	str	int64	int64	timedelta64[us]	object	
211	HD_WAW26_OVERALL	LR3MS4JI4ED74F_WAW	151012	35-39	9	2	0 days 01:04:10	None	S
231	HD_WAW26_OVERALL	LR3MS4JI4EE49D_WAW	154003	35-39	103	22	0 days 01:13:28	None	
251	HD_WAW26_OVERALL	LR3MS4JI4EEC2E_WAW	134019	35-39	203	42	0 days 01:17:42	None	
271	HD_WAW26_OVERALL	LR3MS4JI4ED74D_WAW	151008	35-39	295	62	0 days 01:20:14	None	
291	HD_WAW26_OVERALL	LR3MS4JI4EE071_WAW	174023	35-39	400	82	0 days 01:23:46	None	

5 rows, 14 columns

No selection

Tabela `workout_splits` (format długi – jeden wiersz = jeden split jednej pary): każda para ma tu **19 wierszy** (8 biegów + 8 stacji + Roxzone + ewentualne dodatkowe pomiary), a czas każdego splitu (`split_time`) znów jest **tekstem** `HH:MM:SS`. Taki układ „długi” jest wygodny do zapisu w bazie, ale do analizy porównawczej par przydatni

„szeroki” (jeden wiersz = jedna para) – przekształcamy go w sekcji 4.2.

Q Search...

result_id int64	position int64	split_name str	split_time timedelta64[us]	place float64
271	1	Running 1	0 days 00:04:16	NaN
271	2	1000m SkiErg	0 days 00:04:35	60
271	3	Running 2	0 days 00:05:29	NaN
271	4	50m Sled Push	0 days 00:01:38	44
271	5	Running 3	0 days 00:05:33	NaN
271	6	50m Sled Pull	0 days 00:03:26	52
271	7	Running 4	0 days 00:05:32	NaN
271	8	80m Burpee Broad Jump	0 days 00:04:19	101
271	9	Running 5	0 days 00:05:34	NaN
271	10	1000m Row	0 days 00:05:05	85

20 rows, 5 columns

No selection

4. Funkcje pomocnicze i czyszczenie

Surowe dane (sekcja 3) nie nadają się jeszcze do liczenia. W tym kroku przygotowujemy je do analizy. Konkretnie wykonujemy **cztery** operacje:

- Konwersja czasów** – czasy zapisane jako tekst HH:MM:SS zamieniamy na **sekundy** (liczba), bo tylko na liczbach da się liczyć średnie, korelacje i rysować wykresy. Służy do tego funkcja `time_to_seconds`. Funkcja odwrotna `seconds_to_hms` zamienia sekundy z powrotem na czytelny zapis HH:MM:SS – używamy jej tylko do etykiet w tabelach.
- Wyciągnięcie kary z tekstu** – kara jest zapisana opisowo, np. „SLED PULL (15s)”. Funkcja `parse_penalty_seconds` wyluskuje z takiego tekstu **liczbę sekund** (tu: 15). Brak kary traktujemy jako 0.
- Flaga kary** – dodajemy kolumnę `has_penalty` (prawda/fałsz), która mówi po prostu, czy para w ogóle dostała jakąkolwiek karę.

4. **Porządkowanie rankingów** – kolumny `rank_overall`, `rank_age_group` i `bib_number` zamieniamy na liczby (gdyby gdzieś były tekstem), a całą tabelę sortujemy wg miejsca w grupie 35–39, żeby najlepsze pary były na górze.

Uwaga: `overall_min` (czas w minutach) liczymy tylko dla wygody wykresów – minuty są czytelniejsze na osiach niż sekundy.

Q Search...

result_id int64	rank_age_group int64	rank_overall int64	overall_time timedelta64[us]	overall_sec float64	penalty str	penalty_sec int64	has_penalty bool
210	1	4	0 days 01:02:51	3771	NaN	0	False
211	2	9	0 days 01:04:10	3850	SLED PULL (15s)	15	True
212	3	18	0 days 01:05:49	3949	NaN	0	False
213	4	20	0 days 01:06:15	3975	NaN	0	False
214	5	22	0 days 01:06:17	3977	NaN	0	False

5 rows, 8 columnsNo selection

4.1 Kontrola jakości danych

Sprawdzamy braki, duplikaty i wartości odstające.

- Braki w czasie końcowym: **0**
- Zduplikowane `result_id`: **0**
- Pary z karą: **36 / 209** (17.2%)
- Dyskwalifikacje: **0**
- Bonusy: **0** (kolumna pusta – pomijamy)

Wniosek z kontroli jakości: Dane są **kompletne i bez duplikatów** — możemy analizować całą próbę bez odrzucania wierszy. Kary dotyczą **17%** par — to na tyle dużo, że temat warto sprawdzić osobno (robimy to na wykresie 6.4), ale pamiętając o zastrzeżeniu: z danych nie wynika jednoznacznie, czy sekundy kary są już doliczone do czasu końcowego.

Q Search...

result_id int64	position int64	split_name str	split_time timedelta64[us]	place float64	split_sec float64	split_min float64
271	1	Running 1	0 days 00:04:16	NaN	256	4,2666666666666670
271	2	1000m SkiErg	0 days 00:04:35	60	275	4,5833333333333330
271	3	Running 2	0 days 00:05:29	NaN	329	5,4833333333333330
271	4	50m Sled Push	0 days 00:01:38	44	98	1,6333333333333333
271	5	Running 3	0 days 00:05:33	NaN	333	5,5500000000000000

5 rows, 7 columnsNo selection

4.2 Tabela szeroka — splity per para

Z formatu długiego (`workout_splits`) budujemy tabelę szeroką: jeden wiersz = jedna para, kolumny = poszczególne splity w sekundach. Wyróżniamy 3 grupy: **biegi (8×)**, **stacje funkcjonalne (8×)** i **Roxzone** (przejścia).

Q Search...

result_id int64	rank_age_group int64	overall_sec float64	run_total_sec float64	station_total_sec float64	roxzone_sec float64
210	1	3771	2052	1428	300
211	2	3850	1998	1627	232
212	3	3949	2219	1487	250
213	4	3975	2290	1444	248
214	5	3977	2307	1415	265

5 rows, 6 columnsNo selection

Co daje nam ta tabela? Z 19 osobnych splitów na parę zbudowaliśmy **jeden wiersz na parę** z trzema kluczowymi sumami: `run_total_sec` (łącznie czas 8 biegów), `station_total_sec` (łącznie czas 8 stacji) i `roxzone_sec` (czas przejść). Dodatkowo doliczyliśmy **udziały procentowe** każdego komponentu w czasie końcowym (`run_pct`, `station_pct`, `roxzone_pct`).

Dzięki temu możemy teraz porównywać pary **jak równy z równym** – to ta tabela (**merged, 209 par**) jest podstawą wszystkich dalszych analiz, łącznie z weryfikacją hipotezy w Etapie 2.

Kompletność sum: bieg policzony dla **209/209** par, stacje dla **209/209** – czyli mamy komplet komponentów do porównań.

Ważna uwaga interpretacyjna: `run_total_sec` i `station_total_sec` to **sumy** ośmiu splitów każda. To naturalne dla analizy „bieg vs stacje”, ale trzeba o tym pamiętać przy korelacjach pojedynczych splitów (wykres 6.3) – wracamy do tego niżej.

5. Statystyki opisowe

```
{
  "Najszybsza": "01:02:51"
  "Mediana": "01:26:44"
  "Średnia": "01:27:22"
  "Najwolniejsza": "02:08:56"
  "Odch. std": "00:11:32"
}
```

Z czego składa się czas wyścigu? (trzy komponenty)

Komponent to jedna z trzech składowych, na które dzielimy łączny czas pary. Suma tych trzech komponentów daje (w przybliżeniu) czas końcowy:

- Bieg (8×)** – osiem odcinków biegowych po ok. 1 km, pokonywanych na zmianę ze stacjami. Zwykle największy pojedynczy blok czasu.
- Stacje (8×)** – osiem ćwiczeń siłowo-wytrzymałościowych między biegami (SkiErg, pchanie i ciągnięcie sań, burpees, wioślarz, marsz farmera, wykroki z workiem, rzuty piłką do ściany).
- Roxzone** – strefa przejścia po hali między stacją a kolejnym biegiem; czas „przemieszczania się”, niewidoczny w zwykłym rankingu, ale sumujący się przez cały wyścig.

Tabela poniżej pokazuje, ile **średnio** czasu zajmuje każdy komponent i jaki procent całego wyścigu stanowi.

Q Search...

Komponent	Średni czas (HH:MM:SS)	Średni udział w czasie wyścigu (%)	
str	str	float64	
Bieg (8×)	00:50:53	58,2	
Stacje (8×)	00:29:59	34,4	
Roxzone	00:06:37	7,5	

3 rows, 3 columnsNo selection

Wniosek: największą część wyścigu zajmuje **bieg (≈58%)**, następnie **stacje (≈34%)**, a **Roxzone** to tylko ≈7%. To ważny kontekst do dalszej analizy: skoro bieg jest największym blokiem czasu, naturalnie ma też największy potencjał, by różnicować wynik – ten trop sprawdzimy ilościowo w sekcji 6.3 i w Etapie 2.

Czy przewaga biegu jest istotna? (test Steigera / Williamsa)


Korelacje biegu ($r = 0.96$) i stacji ($r = 0.84$) z wynikiem są **zależne** – liczone na tych samych parach i dzielą wspólne Y. Do ich porównania stosujemy test Williamsa (rekomendowany przez Steigera, 1980) dla korelacji zależnych ze wspólną zmienną:

$t(206) = 11.25, p < 0,001$ – różnica między korelacjami jest istotna statystycznie. Przewaga biegu nie jest przypadkowa.

(Korelacja bieg–stacje w obrębie par: $r = 0.70$.)

6. Wizualizacje

6.1 Rozkład czasów końcowych



Co pokazuje ten wykres? Rozkład czasów końcowych wszystkich par. Słupki = ile par zmieściło się w danym przedziale czasowym.


Wnioski:

- Rozkład jest **prawoskośny (ogon w stronę wolniejszych czasów)** (skośność ≈ 0.60). Średnia (01:27:22) jest wyższa od mediany (01:26:44) – to typowy obraz dla wyników sportowych: większość par skupia się wokół podobnego poziomu, a pojedyncze bardzo wolne pary „rozciągają” skalę w prawo.

- Praktyczny wniosek: do opisu „typowej” pary lepiej używać **mediany** niż średniej, bo średnią zawyżają nieliczne najwolniejsze wyniki.

6.2 Udział komponentów w czasie całkowitym (bieg vs stacje vs roxzone)

Każda para dzieli swój czas na trzy komponenty: **bieg** (8 odcinków), **stacje** funkcjonalne (8 ćwiczeń) i **Roxzone** (przejścia po hali między stacjami). Poniżej pary podzielono na cztery równe grupy wg miejsca (kwartyle): Q1 = najszybsze 25%, Q4 = najwolniejsze 25%. Słupki pokazuje **średni** czas każdego komponentu w danej grupie – widać, gdzie wolniejsze pary tracą najwięcej.



Co pokazuje ten wykres? Pary podzielono na cztery równe grupy wg miejsca (Q1 = najszybsze 25%, Q4 = najwolniejsze). Każdy słupek to **średni** czas danego komponentu w danej grupie.

Wnioski:

- Idąc od Q1 do Q4 (od najlepszych do najgorszych par) rośnie czas każdego komponentu – ale **nierównomiernie**. Największy przyrost między najlepszymi a najgorszymi parami widać w komponentcie: **Bieg** (różnica Q4–Q1 $\approx$ 17.6 min).
- To pierwszy mocny sygnał, że **bieg najsilniej różnicuje pary** – tam, gdzie różnica między grupami jest największa, leży największy potencjał poprawy wyniku. Sprawdzimy to liczbowo korelacją (6.3) i w Etapie 2.

6.3 Co najbardziej decyduje o wyniku? Korelacja komponentów z czasem końcowym

Korelacja mierzy, jak silnie dwie wielkości „idą w parze”. Tu pytamy: jeśli para jest wolniejsza w danym splicie/komponentcie, jak mocno przekłada się to na wolniejszy **czas końcowy**? Im wyższa korelacja (bliżej 1), tym mocniej dany element „ciągnie” wynik.

⚠ **Ważne zastrzeżenie metodologiczne (jak czytać ten wykres):** Zestawienie celowo miesza dwa rodzaje wielkości:

- **pojedyncze splity** (Running 1–Running 8 oraz 8 osobnych stacji),
- **sumy** (run_total_sec = suma 8 biegów, station_total_sec = suma 8 stacji).


Z samej konstrukcji **suma będzie korelować z wynikiem silniej niż każdy pojedynczy split**, który ją tworzy – bo suma agreguje więcej informacji i jest bliżej całego czasu wyścigu. Dlatego **nie porównujemy sum z pojedynczymi splitami** jak równy z równym. Uczciwe porównanie to **suma biegu vs suma stacji** (oba agregują po 8 splitów) – i to porównanie jest właściwym testem naszej hipotezy (rozwijamy je w Etapie 2). Pojedyncze splity traktujemy tu tylko poglądowo: który konkretny odcinek najbardziej „rozjeżdża” pary.

Q Search...

Element str	Typ str	Korelacja z czasem końcowym float64	
Bieg – SUMA (8 odcinków)	Suma komponentu	0,96	
Running 5	Pojedynczy split	0,93	
Running 6	Pojedynczy split	0,92	
Running 7	Pojedynczy split	0,90	
Running 2	Pojedynczy split	0,88	
Running 4	Pojedynczy split	0,86	
Running 3	Pojedynczy split	0,86	
Stacje – SUMA (8 ćwiczeń)	Suma komponentu	0,84	
Running 8	Pojedynczy split	0,80	
Roxzone (przejścia)	Suma komponentu	0,75	

19 rows, 3 columns

No selection




Wnioski (czytane zgodnie z zastrzeżeniem powyżej):

- **Uczciwe porównanie suma vs suma:** `run_total_sec` koreluje z czasem końcowym na poziomie **0.96**, a `station_total_sec` na poziomie **0.84**. Silniejszy okazuje się **bieg** – to wstępne potwierdzenie naszej hipotezy (test statystyczny w Etapie 2).

- **Roxzone** koreluje słabiej (0.75) – to najmniejszy komponent, więc ma też mniejszy wpływ na końcowy wynik.
- **Wśród pojedynczych splitów** najmocniej z wynikiem koreluje **Running 5** (0.93). To ciekawostka pogładowa – pamiętajmy, że pojedynczych splitów nie porównujemy z sumami.
- Przypomnienie: wyższe korelacje sum to **częściowo artefakt agregacji**, dlatego główny wniosek opieramy na porównaniu suma-do-sumy, a nie na tym, że suma „wygrywa” z pojedynczym splitem.

6.4 Wpływ kary na pozycję – pary z karą vs bez kary




Co pokazuje ten wykres? Boxplot (wykres pudełkowy) porównuje rozkład czasów końcowych w dwóch grupach: pary **z karą** i **bez kary**. Linia w środku pudełka to mediana, pudełko obejmuje środkowe 50% par.

Wnioski:

- Mediana czasu par **z karą** to ≈ 92.0 min, a **bez kary** ≈ 85.5 min – czyli pary z karą mają medianę o ≈ 6.5 min **wolniejszy**.
- **Ostrożność w interpretacji:** kara w danych jest zapisana jako **opis tekstowy** i nie wiemy na pewno, czy jej sekundy są już doliczone do czasu końcowego. Dlatego tej różnicy **nie wolno** czytać jako „kara spowodowała gorszy czas” – równie dobrze wolniejsze/mniej doświadczone pary mogą po prostu częściej zaliczać kary. To **obserwacja**, nie dowód przyczynowości, dlatego temat kar świadomie zostawiamy poza główną hipotezą.

6.5 Bieg vs stacje — gdzie tracą wolniejsze pary?



Co pokazuje ten wykres? Każdy punkt to jedna para: oś pozioma — suma biegu, oś pionowa — suma stacji, a **kolor** — czas końcowy (jaśniejszy = wolniejszy). Pozwala zobaczyć, czy pary szybkie w biegu są też szybkie na stacjach i który component bardziej „rozjeżdża” pary.

Wnioski:

- **Rozrzut jest większy w komponencie biegu** (współczynnik zmienności: bieg 14% vs stacje 12%). Większy rozrzut oznacza, że to właśnie tam pary najbardziej się od siebie różnią – czyli tam najłatwiej „zyskać” albo „stracić” względem konkurencji.
- Najjaśniejsze (najwolniejsze) punkty przesuwają się głównie w prawo (w stronę dłuższego biegu), co wskazuje, że **słabszy bieg częściej towarzyszy gorszemu wynikowi** niż słabsze stacje.
- Bieg i stacje są ze sobą skorelowane umiarkowanie ($r \approx 0.70$) – pary dobre w jednym bywają dobre i w drugim, ale nie jest to regułą; są pary „biegowe” i „siłowe”.

7. Wnioski z EDA

- **Split** – czas zmierzony na pojedynczym odcinku trasy. HYROX dzieli wyścig na 8 odcinków biegowych (Running 1–8) i 8 stacji, każdy ma swój split.
- **Stacja funkcjonalna** – jedno z 8 ćwiczeń siłowo-wytrzymałościowych wykonywanych między biegami: SkiErg, pchanie sań (Sled Push), ciągnięcie sań (Sled Pull), burpees z wyskokiem (Burpee Broad Jump), wioślarz (Row), marsz farmera (Farmers Carry), wykroki z workiem (Sandbag Lunges) i rzuty piłką do ściany (Wall Balls). „Funkcjonalne” = ruchy wielostawowe, nie izolowane ćwiczenia siłowni.
- **Roxzone** – strefa przejścia po hali między stacją a kolejnym biegiem. To czas „przemieszczania się”, którego nie widać w zwykłym rankingu, ale który sumuje się przez cały wyścig.

Obserwacje:

- Czasy końcowe par Doubles W 35-39 układają się w prawoskośny rozkład – czołówka jest blisko siebie, a „ogon” wolniejszych par mocno rozciąga skalę.
- Bieg (8 odcinków po ~1 km) to zwykle największy pojedynczy blok czasu, ale stacje i Roxzone często decydują o różnicach między parami o podobnym poziomie biegowym.
- Część par (36/209) ma w danych zapisaną karę. Kara jest podana jako tekst opisowy – z samych danych nie wynika jednoznacznie, czy jej sekundy są już wliczone w `overall_time`, więc każdą analizę kar trzeba opatrzyć tym zastrzeżeniem.
- Analiza korelacji pokazuje, **które splity są najmocniej skorelowane z czasem końcowym** – czyli na których odcinkach różnica między parami najlepiej tłumaczy różnicę na mecie (im wyższa korelacja, tym lepszy „predyktor” wyniku).

8. Propozycje hipotez (wybor 1 do dalszej analizy)

Wszystkie hipotezy poniżej da się przetestować **wyłącznie na danych, które mamy w plikach** – bez dobierania zewnętrznych źródeł.

#	Hipoteza	Co testujemy / które dane	Status danych
H1	O wyniku końcowym decyduje głównie bieg, a nie stacje funkcjonalne.	Korelacja run_total_sec vs station_total_sec z overall_sec; regresja; udziały %.	✅ pełne dane (workout_splits)
H2	Czas w Roxzone różnicuje pary o podobnym poziomie biegowym.	roxzone_sec vs ranking przy zbliżonym run_total_sec; korelacja częściowa.	✅ Roxzone Time + race_replay_splits
H3	Pary z karą mają wolniejszy czas końcowy / niższe miejsce niż pary bez kary.	Porównanie overall_sec i rank_age_group: grupa z karą vs bez; które stacje generują kary.	⚠️ kara to tekst opisowy ; z danych nie wynika jednoznacznie, czy sekundy kary są już doliczone do overall_time – to trzeba zaznaczyć jako ograniczenie
H4	Szybsze pary utrzymują równiejsze tempo biegu (mniejszy rozrzut Running 1–8) niż pary wolniejsze.	Odch. std. czasów Running 1–8 w obrębie pary vs ranking; porównanie biegów 1–4 vs 5–8.	✅ 8 osobnych czasów biegu na parę
H5	Pary, w których obie zawodniczki są z Polski, mają inny czas końcowy niż pary z choć jedną zawodniczką spoza POL.	athletes.country + result_members → flaga „para w pełni POL”; porównanie overall_sec.	⚠️ próba mocno zdominowana przez POL – możliwe tylko proste porównanie grup, bez wniosków o „efekcie gospodarza”

Uwaga metodologiczna: to jest **jeden event** (Warsaw 2026), jedna dywizja i jedna grupa wiekowa. Wnioski dotyczą tej konkretnej próby – nie uogólniamy ich na cały HYROX. Hipotez H3 i H5 nie da się przekształcić w mocne twierdzenia przyczynowe (kara: niejasne czy doliczona; narodowość: brak grupy kontrolnej „u siebie vs na wyjeździe”), dlatego są sformułowane jako **proste porównania grup**.

Rekomendacja: najwięcej materiału analitycznego dają **H1, H2 i H4** – opierają się na kompletnych danych splitowych i prowadzą do jednoznacznych testów.

Wybierz jedną hipotezę, a w etapie 2 zbudujemy pod nią testy statystyczne i wizualizacje potwierdzające/obalające – korzystając tylko z dostępnych kolumn.

ETAP 2: Analiza i weryfikacja hipotezy

Hipoteza

„W tej grupie kobiet startujących w parach (HYROX Doubles, 35–39, Warszawa 2026) szybki bieg silniej idzie w parze z dobrym wynikiem niż szybkie stacje.”

Podejrzewam, że **X = czas biegu** wpływa na **Y = wynik (czas końcowy / miejsce)** silniej niż **X = czas stacji**.

Które tabele i dlaczego

Do tej hipotezy używamy **tylko dwóch** z pięciu tabel — celowo, dla prostoty i przejrzystości (zasada „zaufaj prostocie”):

Tabela	Rola	Co z niej bierzemy
results	zmienna wynikowa Y	overall_time (czas końcowy), rank_age_group (miejsce)
workout_splits	zmienne objaśniające X	8× czas biegu (Running 1–8), 8× czas stacji

Nie używane tu tabele: athletes i result_members (narodowość i skład par), race_replay_splits (czasy przejść Roxzone — istotne dla innej hipotezy). Pominięcie ich nie zubaża analizy — odpowiadają na inne pytania.

Korzystamy z policzonej już w Etapie 1 tabeli merged, która zawiera dla każdej z 209 par: run_total_sec (suma biegu), station_total_sec (suma stacji), overall_sec (czas końcowy) i rank_age_group (miejsce).

Q Search...							
result_id int64	run_total_sec float64	station_total_sec float64	overall_sec float64	rank_age_group int64	run_total_min float64	station_total_min float64	overall_min2 float64
210	2052	1428	3771	1	34,200000000000000	23,800000000000000	62,850000000000000
211	1998	1627	3850	2	33,300000000000000	27,116666666666667	64,166666666666667
212	2219	1487	3949	3	36,983333333333334	24,783333333333335	65,816666666666666
213	2290	1444	3975	4	38,166666666666664	24,066666666666666	66,250000000000000
214	2307	1415	3977	5	38,450000000000000	23,583333333333332	66,283333333333333
5 rows, 8 columns							No selection

Liczba par w analizie: 209 (komplet, bez braków).

E2.1 Test hipotezy – korelacja z czasem końcowym (Y główne)

Pytanie: *jeśli para jest wolniejsza w danym komponencie, jak mocno przekłada się to na wolniejszy czas końcowy?* Mierzymy **korelacją Pearsona (r)**. Im bliżej 1, tym silniejszy związek. **R²** mówi, jaki procent różnic w wyniku tłumaczy dany komponent.

Q Search...			
Komponent str	Korelacja r float64	R ² (% wyjaśnionej zmienności) str	Istotność p str
Bieg (8 odcinków)	0,962	93%	4.7e-119
Stacje (8 ćwiczeń)	0,842	71%	1.9e-57
2 rows, 4 columns			No selection

made with marimo

E2.2 Korelacja z miejscem w grupie (Y wspierające)

Miejsce to ranking (1, 2, 3...), więc używamy **korelacji Spearmana (rho)** – właściwej dla danych rangowych. To kontrola, czy wynik dla czasu trzyma się też przy intuicyjnej dla laika mierze „które miejsce zajęła para”.

🔍 Search...			
Komponent str	Korelacja rho z miejscem float64	Istotność p str	
Bieg (8 odcinków)	0,962	2.9e-118	
Stacje (8 ćwiczeń)	0,810	6.0e-50	
2 rows, 3 columns			No selection


E2.3 Udział komponentów w czasie wyścigu

Ile czasu para średnio spędza biegając, a ile na stacjach? Kontekst: bieg jest też większą *częścią* wyścigu.

- Bieg: **58%** czasu końcowego
- Stacje: **34%** czasu końcowego


E2.4 Wykres punktowy — bieg vs wynik, stacje vs wynik

Każdy punkt to jedna para. Oś pozioma – czas komponentu, oś pionowa – czas końcowy. Im ciaśniej punkty układają się wzdłuż linii, tym silniejszy związek. Dla **biegu** punkty leżą bliżej linii (mocniejsza zależność) niż dla **stacji**.



E2.5 Porównanie siły związku — dwa słupki


Najprostszy wykres odpowiadający na pytanie hipotezy: **który komponent mocniej koreluje z wynikiem?** Oś od zera. Jeden wykres = jedno przesłanie.



E2.6 Struktura czasu wg miejsca (kwartyle)

Pary podzielone na 4 grupy wg miejsca (Q1 = najszybsze 25%, Q4 = najwolniejsze). Słupki = średni czas biegu i stacji w grupie. Kluczowa obserwacja: **różnica w biegu** między najlepszymi a najgłupszymi parami jest **wyraźnie większa** niż różnica w stacjach – czyli to bieg najmocniej różnicuje pary.

Bieg różnicuje pary mocniej niż stacje



E2.7 Podsumowanie testów statystycznych (Etap 2)

Zebrane wyniki testów – sam materiał liczbowy, bez interpretacji (interpretacja i wnioski w **Etapie 3**). Liczby liczone są na żywo z danych, a pogrubienie wskazuje mocniejszy komponent w danym wierszu:

Test	Bieg	Stacje
Korelacja Pearsona z czasem końcowym (r)	0,96	0,84
R ² (% wyjaśnionej zmienności)	93%	71%

Test	Bieg	Stacje
Korelacja Spearmana z miejscem (	rho	)
Udział w czasie wyścigu	≈58%	≈34%

Wniosek liczbowy: związek biegu z wynikiem jest wyraźnie silniejszy niż związek stacji. Co to **oznacza** w praktyce treningowej – rozwijamy w Etapie 3.

ETAP 3: Wyniki, wnioski, podsumowanie i rekomendacja

Cel: zinterpretować wyniki Etapu 2 w kontekście pytania badawczego, sformułować jednoznaczną odpowiedź, przełożyć ją na język nietechniczny (storytelling), podać rekomendację treningową i uczciwie wskazać ograniczenia analizy.

3.1 Powrót do pytania badawczego

Co silniej idzie w parze z dobrym wynikiem pary w HYROX Doubles (kobiety, 35–39, Warszawa 2026): szybki bieg czy szybkie stacje funkcjonalne?

Etap 1 pozwolił poznać dane i wybrać hipotezę (H1), a Etap 2 dostarczył twardych liczb. Teraz łączymy je w odpowiedź.

3.2 Wynik główny (jedno zdanie)

*Gdy rośnie czas biegu, czas końcowy rośnie niemal proporcjonalnie (korelacja **0,96**), a bieg sam wyjaśnia **93%** różnic w wyniku – znacznie więcej niż stacje (korelacja 0,84; 71% wyjaśnionej zmienności). **Hipoteza potwierdzona.***

3.3 To samo po ludzku (storytelling)

Wśród **10 najszybszych par** aż **8 ma też najszybszy bieg**, ale tylko **6 najszybsze stacje**. O czołówce decyduje przede wszystkim to, jak para biega.

Innymi słowy: liczby z Etapu 2 nie są abstrakcją – widać je wprost na liście wyników. Najlepsze pary łączy przede wszystkim mocny bieg.

3.4 Rekomendacja treningowa („jeśli → to”)

Jeśli para z tej grupy chce poprawić wynik, to **trening biegowy daje większy zwrot** niż dopracowywanie stacji – bo to bieg najmocniej przekłada się na czas końcowy i miejsce.

Priorytet treningowy (dla tej próby):

1. **Bieg** – największa dźwignia wyniku; tu inwestycja w formę zwraca się najszybciej.
2. **Stacje** – istotne, ale różnicują pary słabiej; raczej „nie tracić”, niż „nadrabiać”.
3. **Roxzone / detale** – dopiero gdy bieg i stacje są dopracowane.

3.5 Zastrzeżenia (uczciwość analityczna)

- To **jeden event** (Warsaw 2026), jedna dywizja, jedna grupa wiekowa – wniosek dotyczy tej próby, nie całego HYROX.
- Korelacja to nie dowód przyczynowości; bieg jest też większą *częścią* wyścigu (≈58% czasu), co naturalnie wzmacnia jego związek z wynikiem. Dlatego mówimy „decyduje głównie”, a nie „wyłącznie”.

3.6 Podsumowanie całości

- **Etap 1 (EDA)** przygotował i opisał dane oraz wskazał H1 jako najlepiej testowalną hipotezę.
- **Etap 2 (weryfikacja)** dostarczył twardych liczb: bieg $r=0,96$ / $R^2=93\%$ vs stacje $r=0,84$ / $R^2=71\%$.

- **Etap 3 (wnioski)** przekłada to na jednoznaczną odpowiedź: **w tej grupie o sukcesie decyduje przede wszystkim bieg**, a rekomendacją treningową jest priorytet dla pracy biegowej.

▼ [2 Items

0:

Q Search...

int64	result_id int64	overall_sec float64	run_total_sec float64	station_total_sec float64	_cooks_d float64	_hat float64	_stud_resid float64	_dfb_run float64
15	225	4356	2256	1351	0,270459221839576940	0,025970830803951343	5,9608334264532750	-0,23766039027718
208	418	7736	4408	2868	0,185933260210255970	0,117380142986776010	-2,0641387829118480	0,05943255490697
176	386	5866	2853	2472	0,137122361912358600	0,111366794991122060	1,8219204887465141	-0,48218016994039
201	411	6643	4094	1782	0,131805170920601840	0,059977127575018885	2,5216194524325350	0,61085727269382
198	408	6536	3593	1965	0,124955918817143900	0,012173420814826627	5,9595210394349340	0,41060713592740
196	406	6350	3543	1865	0,120298183093940330	0,012945859845913427	5,6217674458109180	0,49762426471062
182	392	6014	3665	1658	0,076063919861876830	0,038413981683904100	2,4179593895833920	0,43891917186304
171	381	5796	3830	1630	0,070400369224875160	0,057289687810412160	-1,8755859789465643	-0,43070330595034
197	407	6409	3470	2257	0,052345399834159416	0,027599922856805265	2,3786119866585340	-0,11512637378851
133	343	5390	3306	1487	0,052255618674758350	0,037085297391060285	2,0328115548799570	0,31264748427358

10 rows, 10 columns

1:

Q Search...

[illegible]

3 rows, 5 columns

Q Search...

Model str	R2 float64	Adj_R2 float64	AIC float64	coef_run float64	coef_station float64	coef_roxzone float64	p_run float64	p_station float64
Bez Roxzone	0,9852371263397715	0,9850902320744955	2394,5737380767490	1,1581203162483430	1,0501753278879051	NaN	0,00000000000000000000	0,0000000
Z Roxzone	0,9999971199605870	0,9999970767599958	653,9921124055307	1,0000311965687225	1,0002102574262925	0,9999419128423157	0,00000000000000000000	

2 rows, 10 columns

No selection